

HEALTHCARE ANALYTICS Y ESTRATIFICACIÓN DE RIESGO EN DIABETES

JUAN ESTEBAN RINCÓN PIRATOBA

ECONOMISTA

ESPECIALISTA EN ESTADÍSTICA

ESPECIALISTA EN ECONOMETRÍA

Contenido

RESUMEN EJECUTIVO	4
1. INTRODUCCIÓN.....	5
1.1 CONTEXTO DEL SECTOR SALUD.....	6
1.2 JUSTIFICACIÓN DEL PROYECTO	7
1.3 OBJETIVO GENERAL	8
1.4 OBJETIVOS ESPECÍFICOS	8
CAPÍTULO 2. DESCRIPCIÓN DEL DATASET Y METODOLOGÍA.....	9
2.1 Fuente de Información.....	9
2.2 Descripción de las Variables	9
2.3 Arquitectura del Proyecto.....	10
2.4 Herramientas Utilizadas	11
CAPÍTULO 3. CALIDAD DE DATOS	11
3.1 Auditoría Inicial	11
3.2 Validación de Rangos	12
3.3 Distribución de la Variable Objetivo	13
CAPÍTULO 4. PERFIL GENERAL DE LA POBLACIÓN Y ANÁLISIS DEMOGRÁFICO	13
4.1 Caracterización General de la Población.....	13
4.2 Distribución por Sexo.....	14
4.3 Prevalencia de Diabetes por Sexo	14
4.4 Distribución por Grupos de Edad	15
4.5 Interacción entre Edad e Hipertensión	16
CAPÍTULO 5. FACTORES CLÍNICOS ASOCIADOS A LA DIABETES	18
5.1 Introducción	18
5.2 Hipertensión y Diabetes.....	18
5.3 Enfermedad Cardíaca y Diabetes.....	19
5.4 Índice de Masa Corporal (BMI).....	20
5.5 Hemoglobina Glicosilada (HbA1c).....	21
5.6 Niveles de Glucosa en Sangre	22

CAPÍTULO 6. FACTORES CONDUCTUALES: HISTORIAL DE TABAQUISMO	23
CAPÍTULO 7. CONSTRUCCIÓN DEL ÍNDICE DE RIESGO POBLACIONAL.....	24
7.1 Justificación.....	24
7.2 Resultados del Risk Score	24
CAPÍTULO 8. SEGMENTACIÓN POBLACIONAL DEL RIESGO	25
CAPÍTULO 9. DASHBOARD EJECUTIVO EN POWER BI	26
CAPÍTULO 10. IMPLICACIONES PARA EPS Y ASEGURADORAS.....	28
CAPÍTULO 11. RECOMENDACIONES ESTRATÉGICAS	29
CAPÍTULO 12. LIMITACIONES.....	29
CAPÍTULO 13. CONCLUSIONES	29

RESUMEN EJECUTIVO

La diabetes mellitus constituye uno de los principales desafíos para los sistemas de salud a nivel mundial debido a su elevada prevalencia, su carácter crónico y los costos asociados a su tratamiento y seguimiento. Para las Entidades Promotoras de Salud (EPS), aseguradoras y organizaciones responsables de la gestión del riesgo en salud, la identificación temprana de poblaciones vulnerables representa una oportunidad estratégica para mejorar los resultados clínicos, optimizar la asignación de recursos y reducir la incidencia de complicaciones asociadas.

El presente proyecto tuvo como propósito analizar los factores asociados a la diabetes y desarrollar un esquema de estratificación poblacional de riesgo utilizando herramientas modernas de analítica de datos y business intelligence. Para ello se empleó un conjunto de datos compuesto por 100.000 registros de pacientes que contenían información demográfica, clínica y conductual relacionada con factores comúnmente asociados al desarrollo de diabetes.

La metodología implementada contempló ocho etapas principales: comprensión del problema de negocio, evaluación de calidad de datos, limpieza y validación de información, almacenamiento en PostgreSQL, análisis exploratorio mediante SQL, identificación de indicadores clave de desempeño (KPIs), construcción de un dashboard ejecutivo en Power BI y desarrollo de un modelo de segmentación poblacional basado en riesgo.

La auditoría inicial de calidad de datos evidenció una base robusta para el análisis. No se identificaron valores nulos en ninguna de las variables evaluadas y se detectaron 3.085 registros duplicados, equivalentes al 3,09% de la información disponible. La validación de rangos permitió confirmar la consistencia de variables críticas como edad, índice de masa corporal (BMI), hemoglobina glicosilada (HbA1c) y niveles de glucosa en sangre.

Los resultados mostraron una prevalencia general de diabetes de 8,50%, lo que indica que aproximadamente uno de cada doce pacientes incluidos en la base presentaba la condición. Desde una perspectiva demográfica, los hombres registraron una prevalencia de 9,75%, superior al 7,62% observado en las mujeres. Adicionalmente, se identificó una relación positiva y consistente entre la edad y la presencia de diabetes, alcanzando una prevalencia de 19,68% en pacientes mayores de 60 años.

Dentro de los factores clínicos analizados, la hipertensión y la enfermedad cardíaca emergieron como algunos de los principales determinantes del riesgo. Los pacientes hipertensos presentaron una prevalencia de diabetes de 27,90%, frente a 6,93% en quienes no registraban dicha condición. De manera similar, los pacientes con antecedentes de enfermedad cardíaca alcanzaron una prevalencia de 32,14%, más de cuatro veces superior a la observada en pacientes sin afecciones cardiovasculares.

El análisis del índice de masa corporal reveló una relación directa entre obesidad y diabetes. Mientras que los pacientes con peso normal registraron una prevalencia de 3,88%, aquellos clasificados dentro de la categoría de obesidad alcanzaron una prevalencia de 17,99%, evidenciando la relevancia de los factores metabólicos en el desarrollo de la enfermedad.

Uno de los principales aportes del proyecto consistió en el desarrollo de un Índice de Riesgo Poblacional construido a partir de seis variables clínicas y demográficas: edad avanzada, hipertensión, enfermedad cardíaca, obesidad, HbA1c elevada y niveles elevados de glucosa. El modelo permitió segmentar la población en distintos niveles de riesgo y demostró una elevada capacidad para discriminar pacientes con probabilidad creciente de presentar diabetes. Mientras los individuos con una puntuación de riesgo igual a cero no registraron casos de diabetes, aquellos con los niveles más altos alcanzaron prevalencias superiores al 76%.

A partir de este índice se construyó una clasificación poblacional compuesta por cuatro categorías: Low Risk, Moderate Risk, High Risk y Very High Risk. Los resultados evidenciaron que los grupos High Risk y Very High Risk, aunque representan menos del 5% de la población total analizada, concentran una proporción significativa de los casos de diabetes identificados. Este hallazgo demuestra el potencial de los modelos de estratificación para orientar programas preventivos y focalizar intervenciones de manera eficiente.

Finalmente, se diseñó un dashboard ejecutivo en Power BI orientado a la toma de decisiones estratégicas. La solución desarrollada permite monitorear indicadores clave, identificar segmentos prioritarios y visualizar patrones de riesgo mediante herramientas interactivas de análisis.

En conjunto, los resultados obtenidos demuestran cómo la integración de técnicas de analítica de datos, SQL, PostgreSQL, Power BI y modelamiento de riesgo puede contribuir a fortalecer los procesos de gestión poblacional en organizaciones del sector salud. Asimismo, evidencian el valor de la analítica como herramienta para apoyar la toma de decisiones basadas en datos y mejorar la eficiencia de programas orientados a la prevención y control de enfermedades crónicas.

1. INTRODUCCIÓN

Las enfermedades crónicas no transmisibles representan actualmente uno de los mayores desafíos para los sistemas de salud a nivel mundial. Entre ellas, la diabetes mellitus ocupa un lugar prioritario debido a su creciente prevalencia, su impacto sobre la calidad de vida de los pacientes y los elevados costos asociados a su tratamiento y seguimiento clínico. De acuerdo con diversos organismos internacionales de salud, la diabetes se ha convertido en

una de las principales causas de mortalidad prematura y discapacidad, generando una presión significativa sobre los recursos financieros y operativos de aseguradoras, hospitales y entidades responsables de la atención médica.

El manejo de esta enfermedad requiere una estrategia integral que incluya prevención, diagnóstico oportuno, monitoreo permanente y control de factores de riesgo asociados. Sin embargo, debido al gran volumen de pacientes que suelen gestionar las organizaciones de salud, resulta cada vez más complejo identificar de manera temprana aquellos individuos con mayor probabilidad de desarrollar complicaciones o requerir intervenciones más intensivas.

En este contexto, la analítica de datos ha adquirido un papel fundamental como herramienta de apoyo para la toma de decisiones. El uso de técnicas de análisis estadístico, inteligencia de negocios y segmentación poblacional permite transformar grandes volúmenes de información clínica en conocimiento útil para la gestión del riesgo, facilitando la identificación de patrones, tendencias y grupos prioritarios de atención.

La capacidad de convertir datos en información accionable representa una ventaja estratégica para las organizaciones del sector salud. Mediante la implementación de modelos de análisis y herramientas de visualización, es posible optimizar la asignación de recursos, fortalecer programas preventivos y mejorar los resultados clínicos de la población afiliada.

Bajo esta perspectiva, el presente proyecto desarrolla un ejercicio integral de Healthcare Analytics orientado a la identificación de factores asociados a la diabetes y a la construcción de un modelo de estratificación poblacional de riesgo. Para ello se empleó un conjunto de datos compuesto por 100.000 registros de pacientes, incorporando variables demográficas, clínicas y conductuales relevantes para el análisis de esta enfermedad.

La solución propuesta combina herramientas ampliamente utilizadas en entornos empresariales y analíticos, incluyendo PostgreSQL para almacenamiento y procesamiento de datos, SQL para análisis exploratorio, Power BI para visualización ejecutiva y DAX para la construcción de indicadores estratégicos. El resultado final es un sistema de análisis capaz de proporcionar información relevante para la toma de decisiones en organizaciones del sector salud.

1.1 CONTEXTO DEL SECTOR SALUD

La transformación digital ha impulsado cambios significativos en la forma en que las organizaciones gestionan la información relacionada con sus usuarios y pacientes. Actualmente, EPS, aseguradoras, hospitales y clínicas generan diariamente grandes

volúmenes de datos provenientes de consultas médicas, resultados de laboratorio, registros administrativos, sistemas de facturación y programas de seguimiento clínico.

A pesar de la abundancia de información disponible, muchas organizaciones enfrentan dificultades para convertir dichos datos en herramientas efectivas de apoyo a la gestión. Con frecuencia, la información se encuentra dispersa entre diferentes sistemas, limitando la capacidad de identificar patrones de comportamiento y grupos de riesgo de manera oportuna.

En el caso específico de la diabetes, la importancia de una adecuada gestión del riesgo es particularmente relevante. Esta enfermedad se encuentra asociada con múltiples complicaciones, incluyendo enfermedades cardiovasculares, insuficiencia renal, neuropatías, amputaciones y eventos cerebrovasculares. Como consecuencia, los pacientes diabéticos suelen generar mayores costos de atención y requieren un seguimiento clínico continuo.

Desde la perspectiva de una EPS o aseguradora, resulta fundamental identificar tempranamente a los individuos con mayor probabilidad de desarrollar diabetes o presentar complicaciones relacionadas. Esto permite implementar programas preventivos, priorizar intervenciones médicas y asignar recursos de manera más eficiente.

La gestión poblacional del riesgo constituye precisamente una de las áreas donde la analítica de datos ofrece mayores oportunidades de generación de valor. Mediante la segmentación de pacientes según características clínicas y demográficas, las organizaciones pueden diseñar estrategias diferenciadas de atención que mejoren los resultados en salud y reduzcan costos operativos.

Por esta razón, cada vez más entidades del sector están incorporando equipos especializados en analítica, ciencia de datos e inteligencia de negocios, con el objetivo de transformar la información disponible en conocimiento estratégico para la toma de decisiones.

1.2 JUSTIFICACIÓN DEL PROYECTO

Uno de los principales retos de los sistemas de salud modernos consiste en pasar de un modelo reactivo a un modelo preventivo. Tradicionalmente, gran parte de los esfuerzos asistenciales se concentran en atender pacientes una vez aparecen las complicaciones o se diagnostica una enfermedad. Sin embargo, este enfoque suele generar mayores costos y menores beneficios clínicos en comparación con estrategias preventivas orientadas a la identificación temprana del riesgo.

La diabetes constituye un escenario ideal para aplicar metodologías de analítica de datos debido a la existencia de múltiples factores asociados que pueden ser monitoreados antes de

que la enfermedad alcance estados avanzados. Variables como la edad, la hipertensión, la obesidad, los niveles de glucosa y ciertos antecedentes clínicos ofrecen información valiosa para identificar poblaciones vulnerables y diseñar programas de intervención temprana.

Desde una perspectiva organizacional, disponer de mecanismos que permitan clasificar pacientes según niveles de riesgo genera beneficios significativos. La segmentación poblacional facilita la focalización de recursos, mejora la eficiencia operativa y permite desarrollar estrategias preventivas dirigidas específicamente a aquellos individuos con mayor probabilidad de presentar eventos adversos.

El presente proyecto busca demostrar cómo herramientas de analítica de datos relativamente accesibles pueden utilizarse para construir soluciones con potencial aplicación en escenarios reales del sector salud. Más allá del análisis descriptivo tradicional, se propone una aproximación orientada a la generación de valor mediante la identificación de grupos prioritarios y el desarrollo de un esquema de estratificación de riesgo.

Asimismo, el proyecto constituye un ejemplo práctico de integración entre análisis estadístico, bases de datos relacionales, inteligencia de negocios y visualización ejecutiva, competencias cada vez más demandadas en organizaciones que buscan fortalecer sus capacidades analíticas y avanzar hacia modelos de gestión basados en evidencia.

1.3 OBJETIVO GENERAL

Desarrollar una solución integral de Healthcare Analytics orientada a identificar factores asociados a la diabetes y construir un modelo de estratificación poblacional de riesgo que facilite la toma de decisiones en organizaciones del sector salud.

1.4 OBJETIVOS ESPECÍFICOS

- Evaluar la calidad e integridad de los datos utilizados en el análisis.
- Identificar patrones demográficos, clínicos y conductuales asociados a la diabetes.
- Calcular indicadores clave de desempeño relacionados con la prevalencia de la enfermedad.
- Analizar la relación entre factores de riesgo y la presencia de diabetes.
- Construir un índice de riesgo basado en variables clínicas y demográficas.
- Segmentar la población en categorías de riesgo para facilitar procesos de priorización.

- Diseñar un dashboard ejecutivo en Power BI orientado a la toma de decisiones.
- Generar recomendaciones estratégicas aplicables a EPS, aseguradoras y organizaciones de salud.

CAPÍTULO 2. DESCRIPCIÓN DEL DATASET Y METODOLOGÍA

2.1 Fuente de Información

La información utilizada en este proyecto proviene del conjunto de datos denominado *Diabetes Prediction Dataset*, disponible públicamente en la plataforma Kaggle. Este conjunto de datos fue diseñado para estudios relacionados con la identificación de factores asociados a la diabetes y contiene información demográfica, clínica y conductual de una población de pacientes.

La selección de este dataset responde a tres criterios fundamentales:

1. Presencia de una variable objetivo claramente definida (diabetes).
2. Disponibilidad de factores de riesgo clínicamente relevantes.
3. Volumen suficiente de observaciones para realizar análisis de segmentación poblacional.

El conjunto de datos constituye una base adecuada para desarrollar ejercicios de Healthcare Analytics debido a la variedad de variables disponibles y a la posibilidad de construir indicadores orientados a la gestión del riesgo.

2.2 Descripción de las Variables

La base de datos contiene nueve variables principales utilizadas para el análisis.

Tabla 1. Diccionario de Variables

Variable	Tipo	Descripción
gender	Categórica	Sexo del paciente
age	Numérica continua	Edad del paciente
hypertension	Binaria	Indica presencia de hipertensión
heart_disease	Binaria	Indica presencia de enfermedad cardíaca

smoking_history	Categorica	Historial de tabaquismo
bmi	Numérica continua	Índice de masa corporal
HbA1c_level	Numérica continua	Hemoglobina glicosilada
blood_glucose_level	Numérica continua	Nivel de glucosa en sangre
diabetes	Binaria	Variable objetivo del análisis


La variable **diabetes** representa el resultado principal de interés y toma valores iguales a 1 cuando el paciente presenta diabetes y 0 cuando no presenta la condición.


Las variables restantes fueron utilizadas como posibles factores explicativos y posteriormente incorporadas dentro del modelo de segmentación de riesgo.

2.3 Arquitectura del Proyecto

Con el fin de replicar un entorno profesional de analítica de datos, el proyecto fue desarrollado utilizando una arquitectura de múltiples etapas que combina herramientas de preparación, almacenamiento, análisis y visualización.

Figura 1. Arquitectura General del Proyecto





Esta arquitectura refleja un flujo de trabajo común en proyectos empresariales de Business Intelligence y permite separar adecuadamente las actividades de almacenamiento, procesamiento y visualización.

2.4 Herramientas Utilizadas

Tabla 2. Herramientas del Proyecto

Herramienta	Función
Excel	Validación inicial de datos
PostgreSQL	Almacenamiento y procesamiento
SQL	Análisis exploratorio
Power BI	Visualización y dashboard
DAX	Construcción de indicadores
GitHub	Documentación y portafolio

Cada herramienta fue utilizada dentro de una etapa específica del proceso analítico, permitiendo reproducibilidad y trazabilidad de los resultados obtenidos.

CAPÍTULO 3. CALIDAD DE DATOS

3.1 Auditoría Inicial

Antes de iniciar cualquier análisis se realizó una evaluación de calidad de datos con el propósito de verificar la integridad de la información disponible.

Tabla 3. Resumen de Calidad de Datos	
Indicador	Resultado
Registros Totales	100.000
Valores Nulos	0
Registros Duplicados	3.085
Variables Analizadas	9

La ausencia de valores faltantes constituye una fortaleza importante del conjunto de datos, ya que reduce la necesidad de aplicar técnicas de imputación y disminuye el riesgo de introducir sesgos adicionales durante el análisis.

Por otra parte, la identificación de 3.085 registros duplicados evidenció la importancia de realizar procesos de validación previos al análisis estadístico. Aunque los duplicados representaban únicamente el 3,09% de la información disponible, su presencia podría afectar la estimación de prevalencias y la construcción de indicadores.

3.2 Validación de Rangos

Adicionalmente se verificó que las variables numéricas presentaran valores coherentes desde una perspectiva clínica.

Tabla 4. Validación de Variables Numéricas

<i>Variable</i>	<i>Mínimo</i>	<i>Máximo</i>
<i>Edad</i>	0,08	80
<i>BMI</i>	10,01	95,69
<i>HbA1c</i>	3,5	9,0
<i>Glucosa</i>	80	300

Los resultados indican que las observaciones se encuentran dentro de rangos plausibles para una población general. Aunque se identificaron algunos valores extremos en BMI, estos no fueron considerados errores evidentes de captura y fueron conservados para el análisis.

La decisión de mantener dichos registros responde a una práctica común en proyectos analíticos, donde la eliminación de valores extremos debe justificarse mediante criterios clínicos o estadísticos claramente definidos.

3.3 Distribución de la Variable Objetivo

Una vez validada la calidad de los datos, se procedió a analizar la distribución de la variable principal de estudio.

Tabla 5. Distribución General de Diabetes

<i>Estado</i>	<i>Pacientes</i>	<i>Porcentaje</i>
<i>Sin Diabetes</i>	91.500	91,50%
<i>Con Diabetes</i>	8.500	8,50%
<i>Total</i>	100.000	100,00%

La distribución observada evidencia un conjunto de datos desbalanceado, situación habitual en estudios epidemiológicos relacionados con enfermedades crónicas. La mayoría de los pacientes no presentan diabetes, mientras que una proporción relativamente menor corresponde a casos positivos.

Desde una perspectiva de negocio, este resultado tiene una interpretación importante: aunque la diabetes afecta a menos del 10% de la población analizada, los costos asociados a esta enfermedad suelen concentrar una proporción significativamente mayor de los recursos destinados a atención médica, seguimiento clínico y manejo de complicaciones.

Por esta razón, la identificación temprana de los individuos con mayor probabilidad de desarrollar la enfermedad representa una oportunidad estratégica para organizaciones responsables de la gestión del riesgo en salud.

CAPÍTULO 4. PERFIL GENERAL DE LA POBLACIÓN Y ANÁLISIS DEMOGRÁFICO

4.1 Caracterización General de la Población

Antes de analizar los factores clínicos asociados a la diabetes, resulta fundamental comprender la composición general de la población estudiada. La caracterización demográfica permite identificar segmentos relevantes y proporciona contexto para interpretar adecuadamente los resultados observados en etapas posteriores del análisis.

El conjunto de datos analizado está compuesto por 100.000 pacientes distribuidos entre diferentes grupos de edad, sexo y condiciones clínicas. Esta amplitud poblacional permite

realizar análisis segmentados con suficiente robustez estadística y facilita la identificación de patrones asociados a la enfermedad.

Desde una perspectiva de gestión poblacional, conocer la estructura de la población constituye el primer paso para diseñar estrategias de prevención efectivas. No todas las intervenciones generan el mismo impacto sobre todos los segmentos poblacionales, por lo que la comprensión de la composición demográfica resulta esencial para optimizar la asignación de recursos.

4.2 Distribución por Sexo

Tabla 6. Distribución de Pacientes por Sexo

<i>Sexo</i>	<i>Pacientes</i>	<i>Porcentaje</i>
<i>Femenino</i>	58.552	58,55%
<i>Masculino</i>	41.430	41,43%
<i>Otro</i>	18	0,02%
<i>Total</i>	100.000	100,00%

La población analizada presenta una mayor representación de pacientes femeninos, quienes constituyen aproximadamente el 58,55% de los registros disponibles. Los hombres representan el 41,43% de la muestra, mientras que la categoría "Other" corresponde a una proporción estadísticamente marginal.

Desde una perspectiva analítica, la distribución observada permite realizar comparaciones entre hombres y mujeres con niveles adecuados de representatividad. Debido al reducido número de observaciones clasificadas como "Other", esta categoría no fue considerada dentro de los análisis comparativos posteriores.

La diferencia en la composición poblacional también resulta relevante para interpretar adecuadamente los resultados de prevalencia. Una mayor proporción de pacientes femeninos implica que los análisis globales podrían verse influenciados por los patrones observados dentro de este grupo, razón por la cual resulta indispensable analizar la prevalencia de diabetes de forma segmentada.

4.3 Prevalencia de Diabetes por Sexo

Tabla 7. Diabetes por Sexo

<i>Sexo</i>	<i>Pacientes</i>	<i>Casos de Diabetes</i>	<i>Prevalencia</i>
<i>Masculino</i>	41.430	4.039	9,75%
<i>Femenino</i>	58.552	4.461	7,62%
<i>Otro</i>	18	0	0,00%

Los resultados muestran diferencias importantes en la prevalencia de diabetes entre hombres y mujeres. Mientras los hombres presentan una prevalencia de 9,75%, las mujeres registran una prevalencia de 7,62%.

La diferencia absoluta entre ambos grupos es de 2,13 puntos porcentuales. En términos relativos, la prevalencia observada en hombres es aproximadamente un 28% superior a la registrada en mujeres.

Este hallazgo resulta relevante para organizaciones del sector salud debido a que permite identificar segmentos poblacionales con diferentes niveles de exposición al riesgo. Aunque el sexo no constituye un factor modificable, sí puede utilizarse como variable de segmentación dentro de programas de prevención y monitoreo.

Desde una perspectiva de gestión del riesgo, estos resultados sugieren la conveniencia de complementar futuras investigaciones con variables relacionadas con estilos de vida, actividad física, alimentación y utilización de servicios de salud, con el fin de comprender mejor los mecanismos que podrían explicar las diferencias observadas entre ambos grupos.

Adicionalmente, este resultado demuestra la importancia de evitar análisis exclusivamente agregados. Si únicamente se considerara la prevalencia global de 8,50%, se perdería información relevante sobre el comportamiento diferencial de la enfermedad entre distintos segmentos de la población.

4.4 Distribución por Grupos de Edad

La edad es uno de los factores más estudiados en la literatura relacionada con enfermedades crónicas. A medida que aumenta la edad, también tiende a incrementarse la exposición acumulada a factores metabólicos, cardiovasculares y conductuales que pueden favorecer el desarrollo de diabetes.

Con el propósito de facilitar la interpretación de los resultados, la población fue agrupada en cuatro categorías etarias representativas.

Tabla 8. Distribución de Pacientes por Grupo de Edad

<i>Grupo de Edad</i>	<i>Pacientes</i>	<i>Casos de Diabetes</i>	<i>Prevalencia</i>
-----------------------------	-------------------------	---------------------------------	---------------------------

<i>0 - 17 años</i>	17.219	82	0,48%
<i>18 - 39 años</i>	28.268	628	2,22%
<i>40 - 59 años</i>	29.458	2.858	9,70%
<i>60 años o más</i>	25.055	4.932	19,68%
<i>Total</i>	100.000	8.500	8,50%

Los resultados evidencian una relación positiva y consistente entre la edad y la prevalencia de diabetes.

Los menores de edad presentan una prevalencia inferior al 1%, mientras que los adultos mayores alcanzan una prevalencia cercana al 20%. En otras palabras, aproximadamente uno de cada cinco pacientes mayores de 60 años presenta diabetes.

Este comportamiento es consistente con la evidencia epidemiológica disponible y refuerza la importancia de la edad como variable fundamental dentro de los procesos de gestión del riesgo.

La progresión observada no es lineal. Entre los grupos de 18-39 años y 40-59 años se observa un incremento importante en la prevalencia, pasando de 2,22% a 9,70%. Posteriormente, el grupo de 60 años o más prácticamente duplica nuevamente dicho valor.

Desde una perspectiva operativa, este hallazgo sugiere que las organizaciones de salud podrían obtener importantes beneficios al implementar programas preventivos diferenciados por grupos etarios. Los adultos mayores representan un segmento prioritario debido a la elevada concentración de casos observada.

Asimismo, los resultados indican que el grupo de 40 a 59 años constituye una etapa crítica para el desarrollo de intervenciones preventivas. Este segmento presenta una prevalencia significativamente superior a la observada en adultos jóvenes, pero aún se encuentra en una fase donde muchas complicaciones asociadas a la diabetes pueden prevenirse mediante intervenciones oportunas.

4.5 Interacción entre Edad e Hipertensión

Uno de los aspectos más interesantes del análisis consiste en evaluar cómo interactúan diferentes factores de riesgo.

Para ello se examinó conjuntamente la edad y la presencia de hipertensión.

Tabla 9. Edad, Hipertensión y Diabetes

<i>Grupo de Edad</i>	<i>Hipertensión</i>	<i>Pacientes</i>	<i>Casos</i>	<i>Prevalencia</i>
0-17	No	17.212	82	0,48%
0-17	Sí	7	0	0,00%
18-39	No	27.770	551	1,98%
18-39	Sí	498	77	15,46%
40-59	No	26.831	2.202	8,21%
40-59	Sí	2.627	656	24,97%
60+	No	20.702	3.577	17,28%
60+	Sí	4.353	1.355	31,13%

Esta tabla constituye uno de los hallazgos más importantes de todo el proyecto.

Los resultados muestran que la hipertensión incrementa significativamente la prevalencia de diabetes dentro de todos los grupos etarios analizados. Sin embargo, el efecto resulta particularmente evidente en edades adultas.

Por ejemplo, en el grupo de 18 a 39 años la prevalencia aumenta de 1,98% a 15,46% cuando existe hipertensión. Esto implica un incremento de casi ocho veces respecto a los pacientes sin dicha condición.

En el grupo de 40 a 59 años, la prevalencia pasa de 8,21% a 24,97%, mientras que en los adultos mayores aumenta de 17,28% a 31,13%.

Desde una perspectiva de gestión poblacional, estos resultados sugieren que los pacientes hipertensos constituyen uno de los segmentos más relevantes para programas de prevención, monitoreo y seguimiento clínico.

De hecho, si una EPS dispusiera de recursos limitados para desarrollar estrategias preventivas, la combinación de edad avanzada e hipertensión representaría uno de los criterios más eficientes para priorizar intervenciones.

Hallazgo Ejecutivo N.º 1

Los adultos mayores con hipertensión presentan una prevalencia de diabetes de 31,13%, la más alta observada entre los segmentos poblacionales amplios analizados.

Este grupo debería ser considerado prioritario dentro de cualquier estrategia de gestión del riesgo, monitoreo preventivo y asignación de recursos clínicos.

CAPÍTULO 5. FACTORES CLÍNICOS ASOCIADOS A LA DIABETES

5.1 Introducción

La diabetes es una enfermedad multifactorial cuyo desarrollo se encuentra influenciado por la interacción de variables genéticas, fisiológicas, metabólicas y conductuales. En consecuencia, el análisis de factores clínicos constituye un componente esencial dentro de cualquier estrategia de identificación temprana del riesgo.

Desde la perspectiva de las organizaciones de salud, las variables clínicas presentan una ventaja importante frente a otros factores de riesgo: generalmente son observables, medibles y susceptibles de seguimiento mediante programas de atención médica.

El presente capítulo analiza la relación entre diabetes y cinco factores clínicos principales:

- Hipertensión.
- Enfermedad cardíaca.
- Índice de masa corporal (BMI).
- Hemoglobina glicosilada (HbA1c).
- Niveles de glucosa en sangre.

El objetivo es determinar cuáles de estas variables muestran las asociaciones más fuertes con la presencia de diabetes y evaluar su utilidad potencial dentro de procesos de estratificación poblacional.

5.2 Hipertensión y Diabetes

La hipertensión arterial constituye una de las enfermedades crónicas más frecuentes en la población adulta y suele coexistir con múltiples trastornos metabólicos, incluyendo diabetes tipo 2.

La relación entre ambas condiciones ha sido ampliamente documentada en la literatura médica debido a que comparten diversos factores de riesgo, entre ellos obesidad, sedentarismo, envejecimiento y resistencia a la insulina.

Tabla 10. Diabetes según Presencia de Hipertensión

<i>Hipertensión</i>	<i>Pacientes</i>	<i>Casos de Diabetes</i>	<i>Prevalencia</i>
---------------------	------------------	--------------------------	--------------------

<i>No</i>	92.515	6.412	6,93%
<i>Sí</i>	7.485	2.088	27,90%
<i>Total</i>	100.000	8.500	8,50%

Los resultados muestran diferencias sustanciales entre ambos grupos.

Los pacientes hipertensos presentan una prevalencia de diabetes de 27,90%, mientras que entre quienes no registran hipertensión la prevalencia es de únicamente 6,93%.

La diferencia absoluta alcanza 20,97 puntos porcentuales.

En términos relativos, los pacientes hipertensos presentan una prevalencia aproximadamente cuatro veces superior.

Este hallazgo tiene implicaciones directas para programas de gestión del riesgo.

Una EPS o aseguradora que desee optimizar la identificación temprana de pacientes susceptibles de desarrollar diabetes podría utilizar la hipertensión como uno de los principales criterios de priorización.

Adicionalmente, estos resultados sugieren oportunidades para fortalecer programas integrados de atención cardiovascular y metabólica.

La coexistencia frecuente entre ambas condiciones indica que intervenciones dirigidas al control de la presión arterial podrían generar beneficios adicionales sobre el riesgo diabético de la población.

Hallazgo Ejecutivo N.º 2

Los pacientes hipertensos presentan una prevalencia de diabetes cuatro veces superior a la observada en pacientes sin hipertensión.

5.3 Enfermedad Cardíaca y Diabetes

La enfermedad cardiovascular representa una de las principales causas de morbilidad a nivel mundial y mantiene una estrecha relación con alteraciones metabólicas como la diabetes.

La coexistencia de ambas condiciones constituye uno de los mayores desafíos clínicos para los sistemas de salud debido a los elevados costos asociados a hospitalizaciones, procedimientos especializados y seguimiento médico.

Tabla 11. Diabetes según Presencia de Enfermedad Cardíaca

<i>Enfermedad Cardíaca</i>	<i>Pacientes</i>	<i>Casos de Diabetes</i>	<i>Prevalencia</i>
<i>No</i>	96.058	7.233	7,53%
<i>Sí</i>	3.942	1.267	32,14%
<i>Total</i>	100.000	8.500	8,50%

Los resultados muestran la asociación más fuerte observada hasta este punto del análisis.

Los pacientes con enfermedad cardíaca presentan una prevalencia de diabetes de 32,14%, frente a 7,53% en aquellos sin antecedentes cardiovasculares.

La diferencia absoluta es de 24,61 puntos porcentuales.

En términos relativos, la prevalencia observada es más de cuatro veces superior.

Este comportamiento resulta particularmente relevante desde una perspectiva de gestión del riesgo porque identifica un segmento poblacional altamente vulnerable.

Las organizaciones de salud suelen disponer de registros detallados sobre pacientes cardiovasculares, lo que facilita la implementación de modelos preventivos dirigidos específicamente a este grupo.

Adicionalmente, la coexistencia de diabetes y enfermedad cardiovascular suele incrementar significativamente los costos de atención.

Por esta razón, la identificación temprana de pacientes con ambos factores representa una oportunidad estratégica para reducir eventos adversos y optimizar recursos clínicos.

Hallazgo Ejecutivo N.º 3

La enfermedad cardíaca fue el factor individual con mayor asociación observada respecto a la presencia de diabetes dentro de las variables clínicas analizadas.

5.4 Índice de Masa Corporal (BMI)

El índice de masa corporal constituye una de las métricas más utilizadas para evaluar el estado nutricional de una población.

Diversos estudios han demostrado que el exceso de peso incrementa significativamente el riesgo de desarrollar diabetes tipo 2 debido a su relación con procesos de resistencia a la insulina y alteraciones metabólicas.

Para facilitar el análisis, los pacientes fueron agrupados en cuatro categorías nutricionales.

Tabla 12. Diabetes según Categoría de BMI

<i>Categoría</i>	<i>Pacientes</i>	<i>Casos de Diabetes</i>	<i>Prevalencia</i>
<i>Bajo peso</i>	8.494	64	0,75%
<i>Normal</i>	22.219	863	3,88%
<i>Sobrepeso</i>	45.751	3.340	7,30%
<i>Obesidad</i>	23.536	4.233	17,99%

Los resultados muestran una relación progresiva entre el incremento del BMI y la prevalencia de diabetes.

La prevalencia pasa de 0,75% en pacientes con bajo peso a 17,99% en pacientes obesos.

Esto implica que los individuos clasificados dentro de la categoría de obesidad presentan una prevalencia aproximadamente 4,6 veces superior a la observada en pacientes con peso normal.

Desde una perspectiva de salud pública, este resultado tiene especial relevancia debido a que el exceso de peso constituye un factor potencialmente modificable.

Mientras variables como edad o antecedentes clínicos no pueden alterarse directamente, la obesidad puede abordarse mediante programas preventivos enfocados en nutrición, actividad física y educación en salud.

Por esta razón, las estrategias orientadas al control del peso corporal suelen generar beneficios tanto sobre la diabetes como sobre múltiples enfermedades crónicas adicionales.

Hallazgo Ejecutivo N.º 4

La obesidad emerge como uno de los principales factores modificables asociados a la diabetes dentro de la población analizada.

5.5 Hemoglobina Glicosilada (HbA1c)

La HbA1c es uno de los indicadores clínicos más utilizados para evaluar el control glucémico de largo plazo y constituye una herramienta fundamental dentro del diagnóstico y seguimiento de pacientes diabéticos.

Para facilitar la interpretación, los pacientes fueron clasificados en tres categorías clínicas.

Tabla 13. Diabetes según Categoría de HbA1c

<i>Categoría</i>	<i>Pacientes</i>	<i>Casos</i>	<i>Prevalencia</i>
<i>Normal</i>	37.857	0	0,00%
<i>Prediabetes</i>	41.346	3.309	8,00%
<i>Rango Diabetes</i>	20.797	5.191	24,96%

Los resultados muestran una relación extremadamente fuerte entre HbA1c y diabetes.

Los pacientes clasificados dentro del rango clínicamente compatible con diabetes presentan una prevalencia cercana al 25%.

Este comportamiento era esperable debido a que la HbA1c forma parte de los criterios diagnósticos utilizados en la práctica clínica.

Sin embargo, su importancia dentro del presente proyecto radica en su capacidad para fortalecer los procesos de segmentación poblacional y estratificación del riesgo.

5.6 Niveles de Glucosa en Sangre

Los niveles de glucosa representan otra de las variables clínicas fundamentales para la identificación de alteraciones metabólicas relacionadas con diabetes.

Tabla 14. Diabetes según Categoría de Glucosa

<i>Categoría</i>	<i>Pacientes</i>	<i>Casos</i>	<i>Prevalencia</i>
<i>Prediabetes</i>	7.025	0	0,00%
<i>Normal</i>	21.119	0	0,00%
<i>Glucosa Elevada</i>	71.856	8.500	11,83%

La totalidad de los casos observados de diabetes se concentra en pacientes con niveles elevados de glucosa.

Este resultado es consistente con la naturaleza clínica de la enfermedad y refuerza la importancia de esta variable como predictor dentro de modelos de estratificación.

No obstante, debido a su estrecha relación con el diagnóstico, los resultados deben interpretarse como una validación clínica del comportamiento esperado de la enfermedad y no necesariamente como evidencia causal independiente.

Conclusión del Capítulo

Los análisis realizados permiten establecer una jerarquía preliminar de factores clínicos asociados a la diabetes.

Considerando las diferencias observadas en prevalencia, los factores podrían ordenarse de la siguiente manera:

1. Enfermedad cardíaca.
2. Hipertensión.
3. Obesidad.
4. HbA1c elevada.
5. Glucosa elevada.

Estos hallazgos constituyen la base conceptual utilizada posteriormente para la construcción del modelo de estratificación de riesgo desarrollado en este proyecto.

CAPÍTULO 6. FACTORES CONDUCTUALES: HISTORIAL DE TABAQUISMO

Además de los factores clínicos y demográficos, el conjunto de datos incluye información relacionada con el historial de tabaquismo de los pacientes. Esta variable resulta relevante debido a la evidencia que relaciona el consumo de tabaco con enfermedades cardiovasculares, alteraciones metabólicas y otras condiciones crónicas.

Tabla 15. Prevalencia de Diabetes según Historial de Tabaquismo

<i>Historial de Tabaquismo</i>	<i>Pacientes</i>	<i>Casos</i>	<i>Prevalencia</i>
<i>Former</i>	9.352	1.590	17,00%
<i>Ever</i>	4.004	472	11,79%
<i>Not Current</i>	6.447	690	10,70%
<i>Current</i>	9.286	948	10,21%
<i>Never</i>	35.095	3.346	9,53%
<i>No Info</i>	35.816	1.454	4,06%

Los exfumadores presentan la prevalencia más alta observada (17,00%). Este resultado podría estar influenciado por factores asociados a la edad o a condiciones de salud previas que motivaron el abandono del hábito.

Aunque la relación observada es menos marcada que la identificada para hipertensión, enfermedad cardíaca u obesidad, los resultados sugieren que el historial de tabaquismo debe considerarse dentro de estrategias integrales de evaluación del riesgo.

CAPÍTULO 7. CONSTRUCCIÓN DEL ÍNDICE DE RIESGO POBLACIONAL

7.1 Justificación

Uno de los objetivos principales del proyecto consistió en desarrollar una herramienta sencilla de segmentación que permitiera identificar grupos con diferentes niveles de riesgo.

Para ello se construyó un índice basado en seis factores:

- Edad ≥ 60 años.
- Hipertensión.
- Enfermedad cardíaca.
- BMI ≥ 30 .
- HbA1c $\geq 6,5$.
- Glucosa ≥ 126 .

Cada factor recibió una puntuación de 1 cuando estaba presente y 0 cuando estaba ausente.

La suma de estos factores generó un score con valores entre 0 y 6.

7.2 Resultados del Risk Score

Tabla 16. Distribución del Risk Score

<i>Score</i>	<i>Pacientes</i>	<i>Casos</i>	<i>Prevalencia</i>
0	13.927	0	0,00%
1	42.070	457	1,09%

2	27.515	2.099	7,63%
3	11.533	3.063	26,56%
4	3.902	2.114	54,18%
5	954	691	72,43%
6	99	76	76,77%

Los resultados muestran una relación prácticamente monotónica entre el número de factores de riesgo presentes y la prevalencia de diabetes.

Mientras los pacientes con score 0 no registran casos de diabetes, aquellos con score 6 presentan prevalencias superiores al 76%.

Este comportamiento valida la utilidad del índice como herramienta de segmentación poblacional.

Hallazgo Ejecutivo N.º 5

La prevalencia de diabetes aumenta desde 0,00% hasta 76,77% a medida que se acumulan factores de riesgo clínicos y demográficos.

CAPÍTULO 8. SEGMENTACIÓN POBLACIONAL DEL RIESGO

Con base en el score desarrollado, los pacientes fueron clasificados en cuatro categorías de riesgo.

Tabla 17. Categorías de Riesgo

<i>Categoría</i>	<i>Pacientes</i>	<i>Prevalencia</i>
<i>Low Risk</i>	55.997	0,82%
<i>Moderate Risk</i>	39.048	13,22%
<i>High Risk</i>	4.856	57,76%
<i>Very High Risk</i>	99	76,77%

La segmentación obtenida constituye uno de los principales resultados del proyecto.

Los grupos High Risk y Very High Risk representan aproximadamente el 5% de la población analizada, pero concentran una proporción desproporcionadamente alta de los casos de diabetes.

Desde una perspectiva operativa, esto permite focalizar intervenciones preventivas sobre segmentos específicos sin necesidad de intervenir la totalidad de la población.

Hallazgo Ejecutivo N.º 6

Menos del 5% de la población concentra más de un tercio de todos los casos de diabetes identificados en el análisis.

CAPÍTULO 9. DASHBOARD EJECUTIVO EN POWER BI

Como producto final se desarrolló un dashboard interactivo compuesto por cuatro páginas:

1. Executive Overview

Presenta los principales KPIs del proyecto, incluyendo prevalencia general, casos de diabetes y distribución de pacientes por categoría de riesgo.

2. Clinical Risk Factors



Permite analizar la relación entre diabetes y variables clínicas como edad, BMI, hipertensión y enfermedad cardíaca.


3. Population Risk Segmentation

Muestra la distribución de pacientes según el índice de riesgo desarrollado.

4. Strategic Insights

Resume los hallazgos más relevantes y las recomendaciones para tomadores de decisiones.





CAPÍTULO 10. IMPLICACIONES PARA EPS Y ASEGURADORAS

Los resultados obtenidos demuestran que la analítica de datos puede utilizarse para fortalecer estrategias de gestión poblacional del riesgo.

Entre las principales aplicaciones potenciales se encuentran:

- Identificación temprana de pacientes vulnerables.
- Priorización de programas preventivos.
- Optimización de recursos clínicos.
- Seguimiento de pacientes con múltiples factores de riesgo.
- Monitoreo de indicadores poblacionales de salud.

La capacidad de segmentar pacientes según niveles de riesgo permite pasar de un enfoque reactivo a uno preventivo, generando beneficios tanto clínicos como financieros.

CAPÍTULO 11. RECOMENDACIONES ESTRATÉGICAS

A partir de los hallazgos identificados se proponen las siguientes acciones:

1. Implementar modelos de estratificación poblacional para identificar pacientes prioritarios.
 2. Fortalecer programas de seguimiento dirigidos a adultos mayores e hipertensos.
 3. Integrar programas de control cardiovascular y metabólico.
 4. Incrementar estrategias de prevención y manejo de obesidad.
 5. Utilizar dashboards ejecutivos para monitoreo continuo de indicadores críticos.
 6. Incorporar variables socioeconómicas, geográficas y de utilización de servicios en futuros modelos de riesgo.
-

CAPÍTULO 12. LIMITACIONES

- El dataset utilizado no corresponde a una población real específica.
 - Algunas variables están estrechamente relacionadas con el diagnóstico de diabetes.
 - El análisis es observacional y no permite establecer causalidad.
 - No se dispone de variables socioeconómicas o geográficas que podrían enriquecer el modelo.
-

CAPÍTULO 13. CONCLUSIONES

El presente proyecto permitió desarrollar una solución integral de Healthcare Analytics utilizando PostgreSQL, SQL, Power BI y DAX para analizar factores asociados a la diabetes y construir un modelo de estratificación poblacional.

Los resultados evidenciaron que la enfermedad cardíaca, la hipertensión, la obesidad y la edad avanzada constituyen algunos de los factores más relevantes asociados a la presencia de diabetes.

Asimismo, la construcción del índice de riesgo permitió segmentar exitosamente la población en categorías con prevalencias claramente diferenciadas, demostrando el potencial de la analítica de datos para apoyar la gestión del riesgo en organizaciones del sector salud.

Finalmente, el dashboard desarrollado proporciona una herramienta visual e interactiva para apoyar procesos de toma de decisiones basados en evidencia, contribuyendo a una gestión más eficiente de programas preventivos y estrategias de salud poblacional.

REFERENCIAS

Mustafa, M. (s.f.). *Diabetes Prediction Dataset*. Kaggle. Recuperado de <https://www.kaggle.com/datasets/iammustafatz/diabetes-prediction-dataset>

World Health Organization. (2024). *Obesity and overweight*. <https://www.who.int>

Microsoft. (2025). *Power BI Documentation*. <https://learn.microsoft.com/power-bi>

PostgreSQL Global Development Group. (2025). *PostgreSQL Documentation*. <https://www.postgresql.org/docs/>